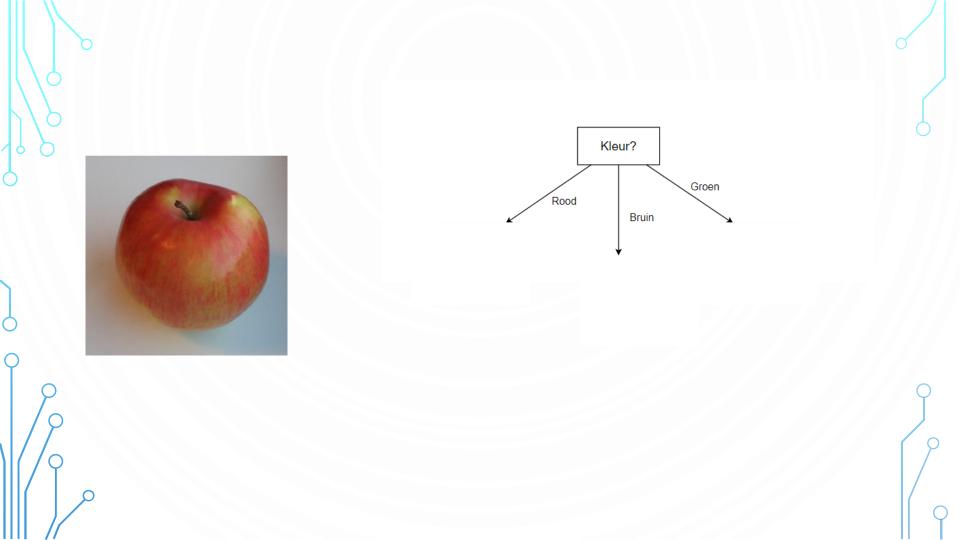
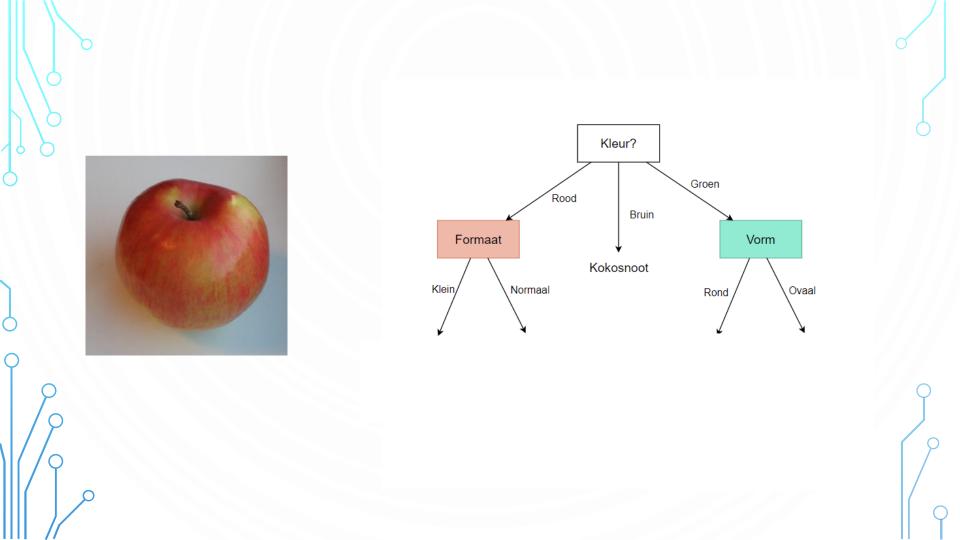
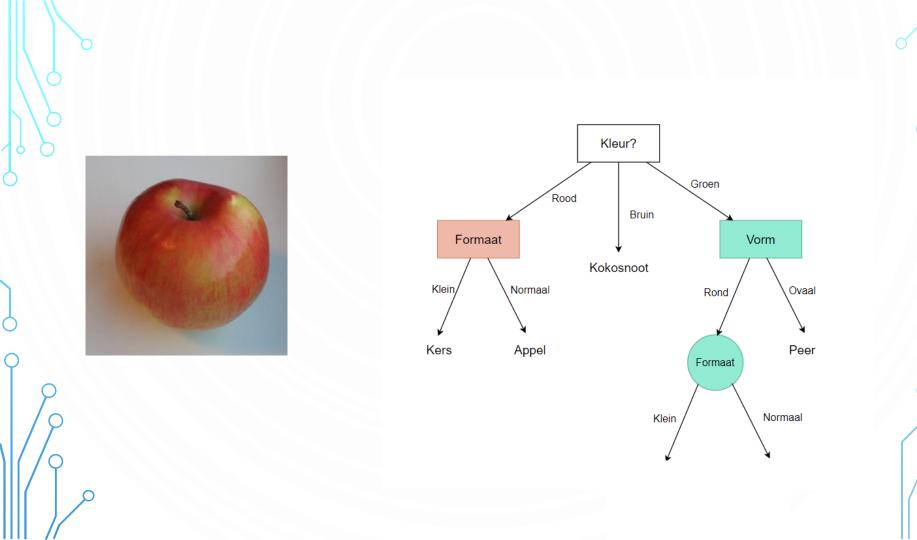
## **DECISION TREES**

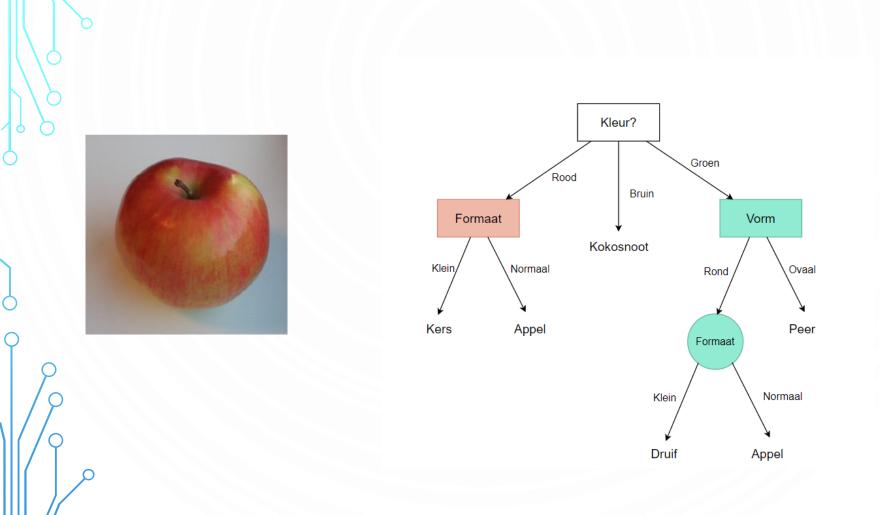
JENS BAETENS

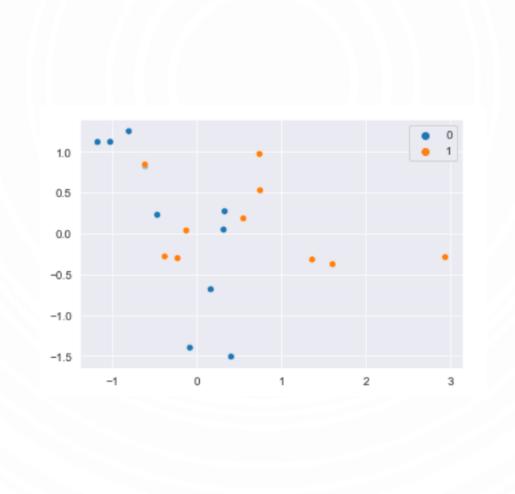


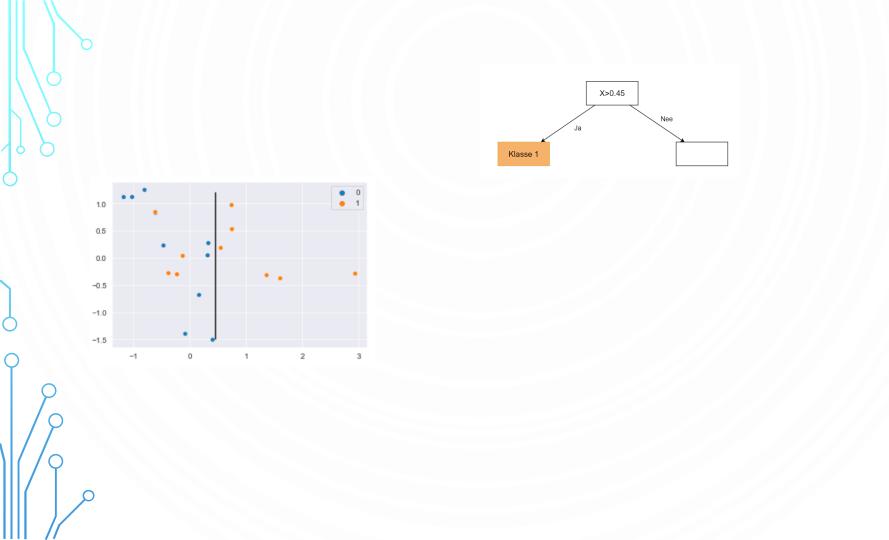


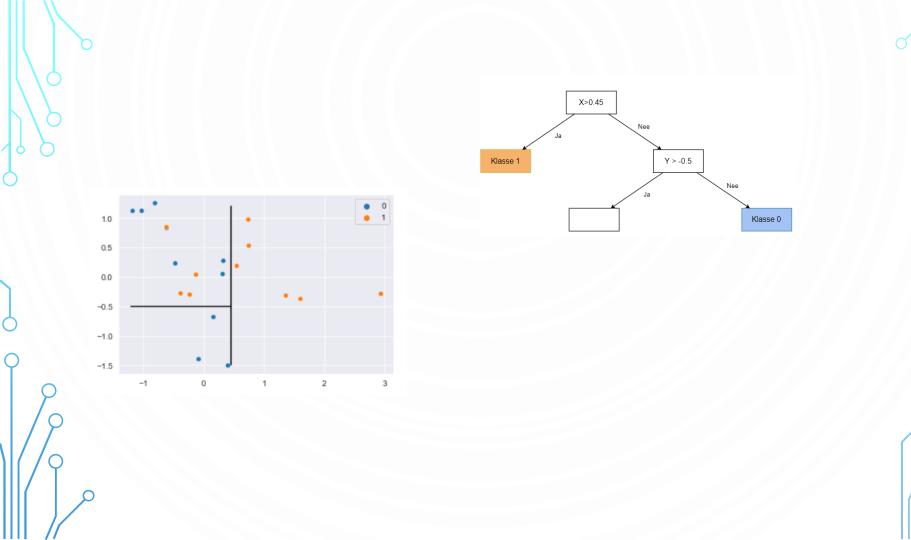


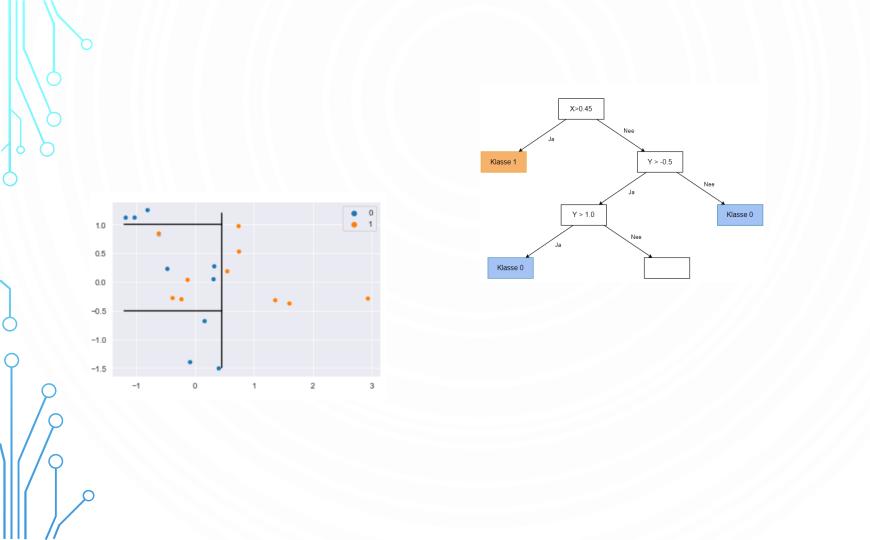


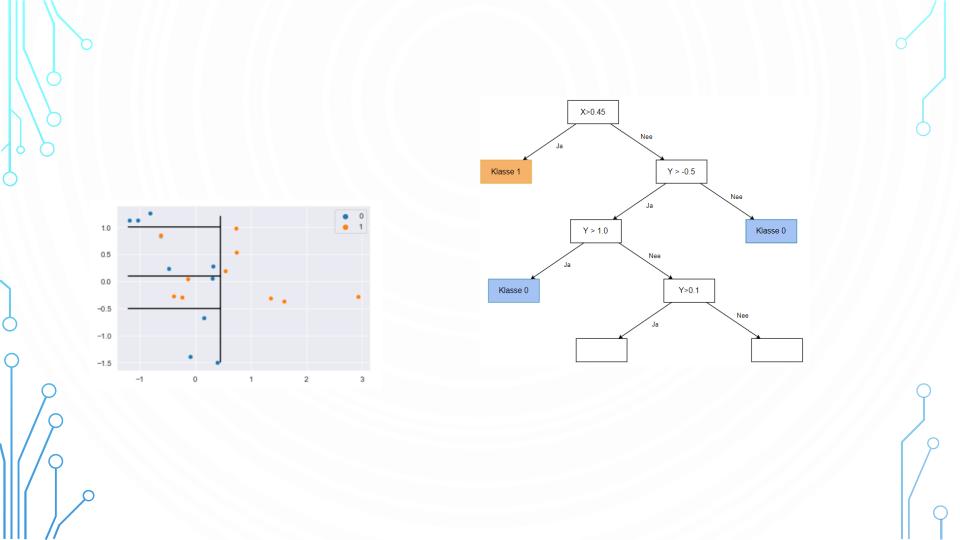


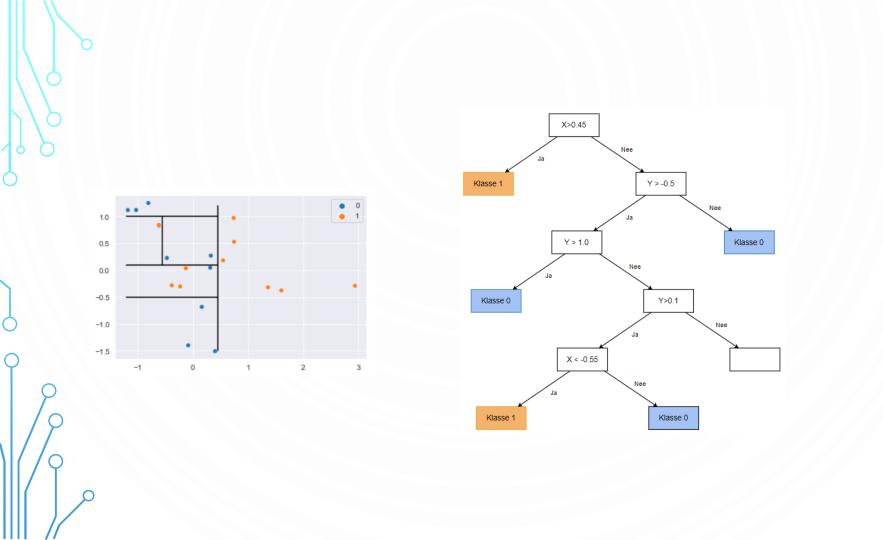


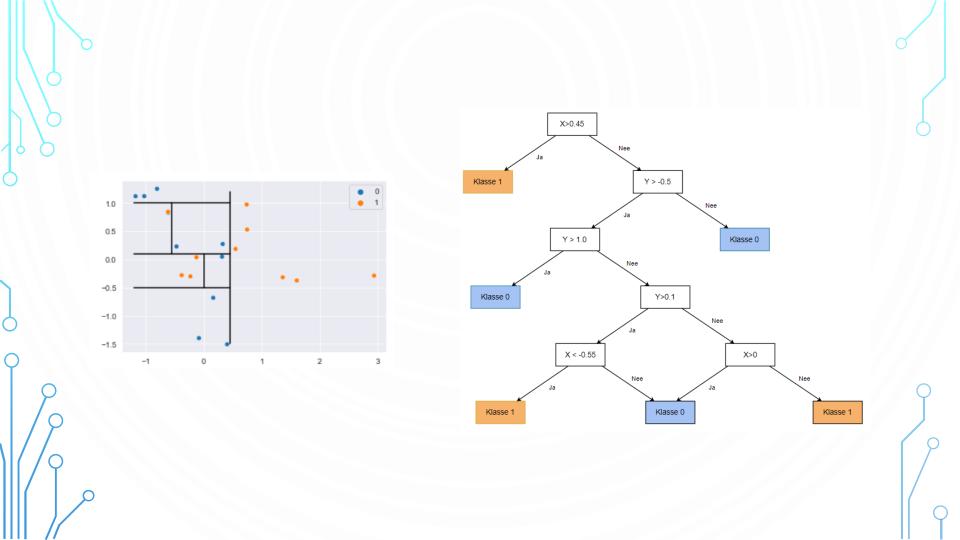












### HOE BEPALEN VAN DE SCHEIDINGSLIJN?

Bereken entropie (maatstaf voor de wanorde) voor elke mogelijke verdeling

$$H = \sum_{i=1}^{N} p_i \log_2(\frac{1}{p_i}) = -\sum_{i=1}^{N} p_i \log_2(p_i)$$

P<sub>i</sub> is het percentage van elke klasse in een gebied

Bereken het verschil met de entropie voor en na de verdeling => Information gained => Hoe groter hoe beter

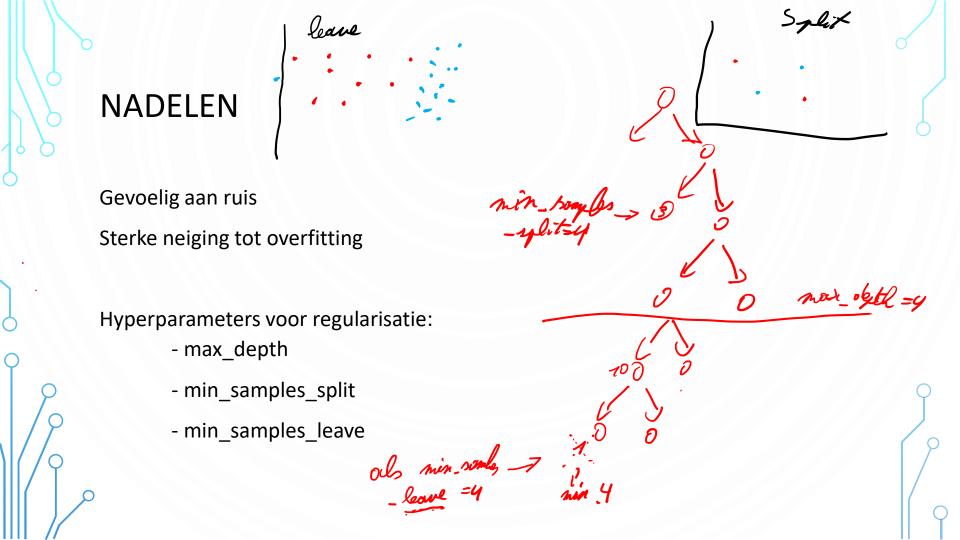
### ALTERNATIEF VOOR ENTROPIE

Logaritmes voor berekenen entropie zijn rekenintensief

Alternatieve manier: Gini impurity

$$G = 1 - \sum_{i=1}^{N} p_i^2$$

Beste scheidingslijn heeft de kleinste Gini Impurity

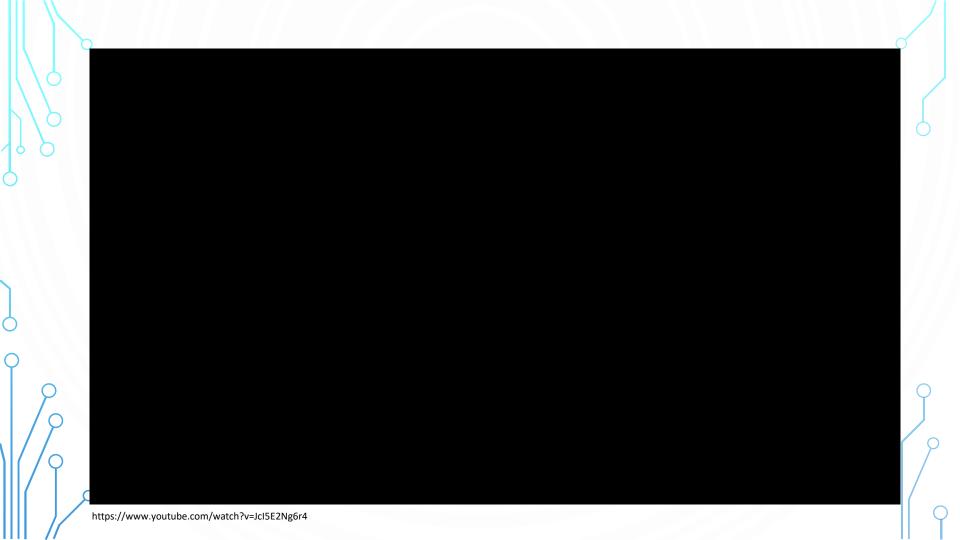


### **VOORDELEN**

Eenvoudig algoritme en daardoor ook snel

Men kan redeneren op het resultaat

- Niet mogelijk bij SVM, LR, Naïve Bayes, ...



Is Rusland groter dan Afrika?

Ja: ...

Nee: ...

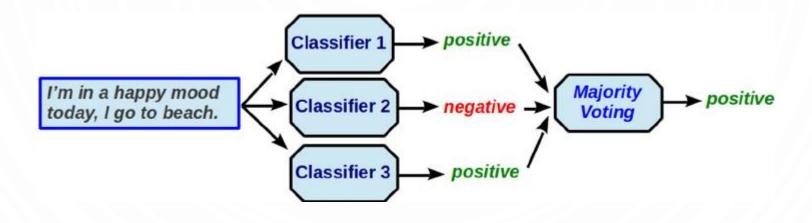




Condorcet's jury theorem

Given a jury of voters and assuming independent errors. If the probability of each single person in the jury of being correct is above 50% then the probability of the jury being correct tends to 100% as the number of persons increase.

Nicolas de Condorcet (1743 - 1794)



### **RANDOM FORESTS - PARAMETERS**

Aantal bomen

Aantal features per boom: int, float, sqrt / auto, log2, default

Bagging: Gebruik slechts een deel van de data om elke boom te trainen

Oob score: Aangezien niet alle data gebruikt wordt om elke boom te trainen. Gebruik deze data om de

bomen te valideren. Vooral handig als er niet genoeg data is om een aparte validatieset te behouden.