



The background features a series of concentric, light gray circles centered on the slide. In the four corners, there are stylized circuit board traces in a light blue color, with small circles at the end of the lines, resembling nodes or components of a network.


NEURAL NETWORK

JENS BAETENS



Biologische computer / Neural Network







	Brain	Computer
number of processors	≈ 10 billion <i>neurons</i> (massively parallel)	1 CPU <i># cores</i> (intrinsically serial)
processor complexity	simple <i>→ neurons</i> inaccurate <i>irregular</i>	complex accurate
processor speed	slow <i>→ neuron</i> (millisec)	fast (nanosec)
inter-processor communications	fast (μsec)	<u>slow</u> (millisec)
learning mode	learn from experience	manual programming
failure robustness	many neurons die without drastic effect	single fault often leads to system failure
memory organization	content addressable (CAM)	location addressable (LAM)

↑
transistors
milyarden

MENSELIJK NEURON



ARTIFICIEEL NEURON/PERCEPTRON



ARTIFICIEEL NEURON/PERCEPTRON

Summing function


$$\mu = w_1 * x_1 + w_2 * x_2 + \dots + w_6 * x_6$$

Activation function (bvb sigmoid)


$$y = f(\mu) = \frac{1}{1 - e^{-\mu}}$$

$$f(x) = \frac{1}{1 - e^{-x}}$$

↳ afgeleide te bepalen → belangrijk om te weten



ARTIFICIAL NEURON/PERCEPTRON



→ outputs

Input Layer

Layer/layer

$$3 \times 3 = 9$$

$$3 \times 4$$


Inputs

$$4 \times 1$$

Output Layer

$$9 + 12 + 4$$

= 25 gewichte
om te trainen



Feed Forward NN

NETWERK OF NEURONS

Te kiezen (hyperparameters)

- Architectuur van het network
- Hoe leert het network
- Activatiefunctie

FF, RNN, ...

#lagen

#neuronen per laag

→ optimizers → Standard is OK.

$$f(x) = \frac{1}{1 + e^{-x}} \quad (\text{sigmoid})$$

NETWORK ARCHITECTUUR


<https://www.asimovinstitute.org/neural-network-zoo/>

*CNN → Computer
Visie*
↑

Feed Forward (FF)




Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)



Auto Encoder (AE)



Deep Convolutional Inverse Graphics Network (DCIGN)




FEEDFORWARD NEURAL NETWORK

Hoeveel gewichten?

32

Informatie gaat van
links naar rechts

- FeedForward




FEEDFORWARD NEURAL NETWORK

$n_{\text{inputs}} = n_{\text{features}}$

One-hot encoding

Prob of each class -

~~28 x 28 pixels~~
→ klein




27 x 27

BACKPROPAGATION

Omgekeerde beweging van FeedForward

Gradient Descent Algoritme gebaseerd op de fout

↳ afgeleiden




learning rate

Wiskunde:

<https://medium.com/@14prakash/back-propagation-is-very-simple-who-made-it-complicated-97b794c97e5c>

<https://mattmazur.com/2015/03/17/a-step-by-step-backpropagation-example/>



BACKPROPAGATION




Error functie

- Afhankelijk van de learning rate (automatisch = ADAM)
- Epochs = aantal keer volledige trainingsdata gezien

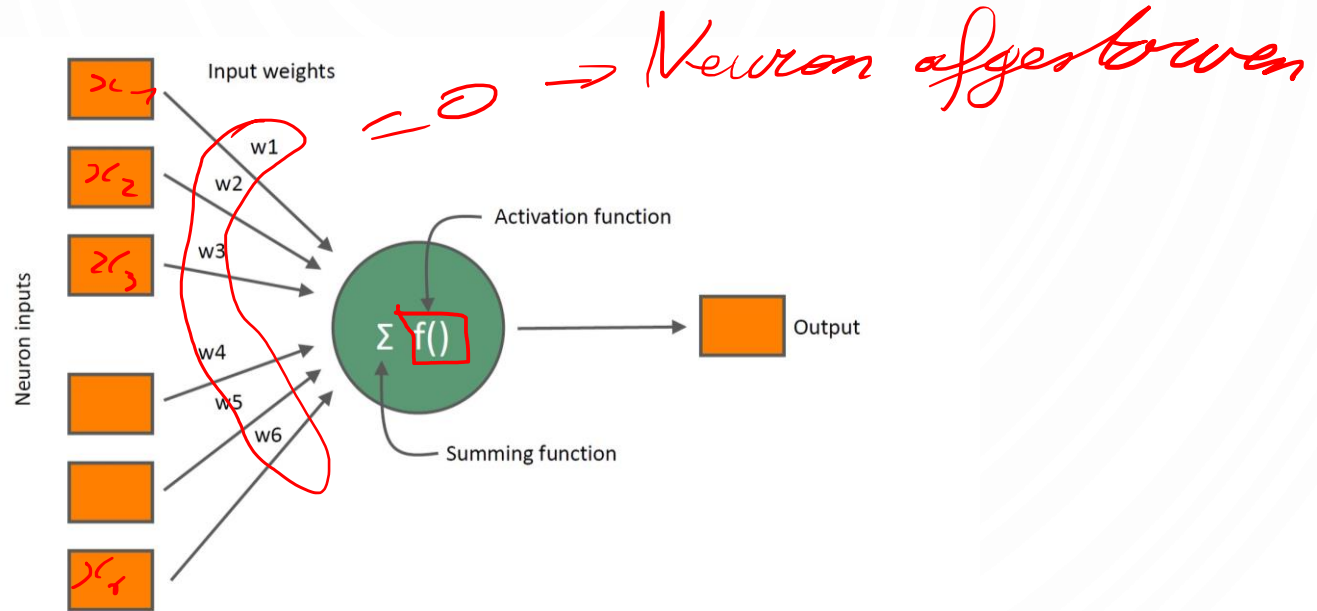
Data augmentation

- Spiegelen
- roteren
- inzoomen
- verplaatsen



#keer **VOLLEDIGE**
dataset over het
systeem

ACTIVATION FUNCTION




STEP FUNCTION

$X > 0 \Rightarrow \text{output} = 1$


$X < 0 \Rightarrow \text{output} = 0$

Nadelen:

- Enkel ja of nee
- Geen indicatie hoe verkeerd of correct het neuron is
- Backpropagation werkt niet (afgeleide is 0) \rightarrow *problem voor learning*
- Meerdere klassen die op 1 staan, welke is het dan?
 \rightarrow *problem bij one-hot encoding*



LINEAIRE FUNCTION



Output = $X \cdot a$

Nadelen:

- Enkele lineaire scheidingen mogelijk
- Afgeleide is constant en geen relatie meer met de ingang

Gebruikt voor:

- Input layer ($a_1 = 1$)


- Output layer voor regressie uit te voeren \rightarrow ~~regressie~~

\hookrightarrow kwadratische verbanden door hidden layer(s)

SIGMOID FUNCTION

↳ *benadering step-functie*

$$f(x) = \frac{1}{1+e^{-x}}$$



Nadelen:


- Vanishing gradient problem (Afgeleidde gaat naar 0 bij grote $|x|$)
- Vooral problem bij veel hidden layers
- Rekenintensief

Gebruikt voor:

- Soms in output layer voor classificatie

HYPERBOLIC TANGENT

$$f(x) = \tanh(x)$$



Nadelen:

- Vanishing gradient problem
- Rekenintensief

Gebruikt voor:

- Zelden maar kan voor output in classificatie

SOFTMAX FUNCTION


$$\sigma(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Generalisatie van sigmoid

Gebruikt voor:


- In output layer voor classificatie
- Kan meerdere klassen tegelijkertijd aangeven

Hand of Kart



Huis
→ Boom
→ Zon

Multi-label
classificatie



RECTIFIED LINEAR UNIT (RELU)

$$f(x) = \max(0, x)$$

Voordelen:

- Kan elke functie benaderen

- Heel rekenefficient


- Sparse activation

Nadelen:

- Dode Neurons blijven dood

Gebruikt voor:

- Hidden layers



*geen a → moet niet getraind constant = 0 Linear
→ geen extra gewicht-werken*

↳ Combinatie Relu

LEAKY ^{Linear} RELU _{Rectified Unit}

Voordelen:

- Neurons gaan niet dood


Nadelen:

- Meer parameters om te trainen

a per neuron

Gebruikt voor:

- Hidden layers



ACTIVATION FUNCTIONS - SAMENVATTING

Hidden layers

- Eerste relu, indien problemen leaky relu
- Geen sigmoid of tanh

Output layer


- Regressie: Lineaire activation function
- Classification:
 - Slechts 1 klasse tegelijkertijd: Sigmoid *efficiënter dan softmax)*
 - Meerdere klassen tegelijkertijd: Softmax

UNDERFITTING EN OVERFITTING

Veel lagen/neuronen *↑* *Veel epochs nodig*

Te groot netwerk/ niet voldoende data -> overfitting -> Meer data *1 eenvoudiger model*

Te klein netwerk -> underfitting -> Complexer netwerk
geen hidden *1 hidden*



WEIGHT REGULARISATION


Straf gebruik van hoge gewichten af zodat er gefocust wordt op de belangrijke

Extra kost op basis van L2-norm of L1-norm.

Neuron : $|w_1| + |w_2| + |w_3| + |w_4| + |w_5| + |w_6| = V$ (L₁-norm)

$$w_1^2 + w_2^2 + w_3^2 + w_4^2 + \dots = V \quad (\text{L}_2\text{-norm})$$

UNDERFITTING EN OVERFITTING - DROPOUT *by training*



<https://www.youtube.com/watch?v=NhZVe50QwPM&t>

UNDERFITTING EN OVERFITTING - DROPOUT

Techniek om overfitting te voorkomen

Willekeurig uitschakelen van neurons *bij training*

- Andere neurons moeten inspringen om een correct resultaat te geven
- Vermijd dat andere neurons afsterven

Bootst een ensemble van netwerken na wat het robuster en accurater maakt

HOE NEURAAL NETWERK IMPLEMENTEREN

*eerder in
onderzoek* ←
*meer vrijheid
op netwerk-
structuur
architectuur*

